

Praktikum 5: Machine Learning – Decision Tree

Muhammad Shiddiq 1 - 0110222199 ¹

¹ Teknik Informatika, STT Terpadu Nurul Fikri, Depok

E-mail: muhammadshiddiq785@gmail.com


Abstract. Pohon keputusan (Decision Tree) adalah algoritma pembelajaran mesin yang kuat dan mudah diinterpretasikan, digunakan untuk tugas klasifikasi dan regresi. Model ini bekerja dengan memecah dataset menjadi himpunan bagian yang lebih kecil secara berulang kali, sambil mengembangkan pohon terkait secara bersamaan. Strukturnya menyerupai diagram alir, terdiri dari simpul akar (mewakili seluruh dataset), cabang (mewakili hasil pengujian fitur), simpul internal (mewakili uji fitur tunggal), dan simpul daun (mewakili keputusan atau label kelas). Proses pembentukan pohon ini didasarkan pada metrik seperti information gain atau indeks Gini untuk memilih fitur terbaik guna membagi data pada setiap langkah. Keunggulan utamanya meliputi kemampuannya untuk menangani data non-linear, tidak memerlukan normalisasi data, dan mudah divisualisasikan, menjadikannya pilihan populer untuk pengambilan keputusan yang transparan di berbagai bidang.

1. Praktikum Mandiri – Membuat Model Decision Tree untuk mencari species iris bunga

Pembuatan model Decision Tree ini bertujuan untuk mengklasifikasikan spesies bunga Iris (Iris-setosa, Iris-versicolor, atau Iris-virginica) berdasarkan empat fitur utama: Sepal Length (Panjang Kelopak), Sepal Width (Lebar Kelopak), Petal Length (Panjang Mahkota), dan Petal Width (Lebar Mahkota). Setelah memuat dan membersihkan data, dataset dibagi menjadi data pelatihan (*training*) dan pengujian (*testing*) (menggunakan $\text{test_size}=0.2$ dan $\text{stratify}=y$ untuk distribusi kelas yang seimbang). Model Decision Tree kemudian dilatih menggunakan data pelatihan, dengan mengoptimalkan pembagian simpul berdasarkan kriteria Gini dan membatasi kedalaman maksimum pohon (*max_depth*) untuk mencegah *overfitting*. Setelah pelatihan, model diuji menggunakan data pengujian untuk menghitung metrik kinerja seperti akurasi, Confusion Matrix, dan Classification Report. Analisis lebih lanjut, termasuk pemvisualisasian pohon dan perhitungan Feature Importance, menunjukkan bahwa Petal Length dan Petal Width adalah fitur yang paling krusial dalam memprediksi spesies Iris. Hasil pengujian menunjukkan akurasi yang sangat tinggi (93.33% dengan $\text{max_depth}=4$) dan menemukan bahwa $\text{max_depth}=3$ bahkan memberikan akurasi yang lebih optimal (96.67%).

1.1 Membuat Folder


Langkah pertama kita harus membuat folder yang terstruktur dan juga rapih di google drive.



Gambar 1. Membuat folder di google drive, agar mudah untuk diakses.

1.2 Membuat file notebook google colab


Selanjutnya membuat file notebook di google colab untuk praktikum.



Gambar 2. Membuat file google colab

1.3 Menghubungkan google colab dengan google drive


Selanjutnya menghubungkan google colab dengan google drive menggunakan perintah "From google.colab import drive
Drive.mount('/content/drive')".



Gambar 3. Menghubungkan google colab dengan google drive

1.4 Meng install pandas

Selanjutnya meng install library pandas dengan perintah "!pip install pandas".



Gambar 4. Meng install pandas.

1.5 Meng import library yang akan digunakan

Langkah pertama dalam praktikum ini adalah melakukan import terhadap seluruh library yang dibutuhkan.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
```

Gambar 5. Mengimport library

Tabel 1. Penjelasan Library

# Baris	Library / Fungsi	Kategori	Deskripsi
1	pandas as pd	Data Handling	Digunakan untuk mengimpor dan memanipulasi data dalam bentuk DataFrame (tabel). Ini penting untuk membaca file CSV (Iris.csv) dan memilih kolom fitur.
2	numpy as np	Komputasi Numerik	Digunakan untuk operasi matematika tingkat tinggi pada array dan matriks. Walaupun sering digunakan di belakang layar oleh library lain (seperti pandas dan scikit-learn), impor ini adalah praktik standar.
3	matplotlib.pyplot as plt	Visualisasi Data	Library dasar untuk membuat grafik dan plot, seperti visualisasi pohon keputusan (Decision Tree) dan grafik Feature Importance.
4	seaborn as sns	Visualisasi Data	Library yang dibangun di atas Matplotlib, digunakan untuk membuat visualisasi statistik yang lebih menarik dan informatif, seperti barplot untuk Feature Importance.
5	train_test_split	Persiapan Data	Fungsi dari scikit-learn yang digunakan untuk membagi dataset menjadi dua bagian: data pelatihan (training) dan data pengujian (testing). Ini krusial untuk mengevaluasi model secara tidak bias.
6	DecisionTreeClassifier	Model Machine Learning	Kelas model utama yang digunakan untuk melatih algoritma Pohon Keputusan untuk tugas klasifikasi.
6	plot_tree	Model Machine Learning	Fungsi untuk menghasilkan visualisasi dari pohon keputusan yang telah dilatih, memungkinkan kita memahami aturan klasifikasi yang dipelajari model.
7	accuracy_score	Evaluasi Model	Fungsi untuk menghitung metrik Akurasi, yaitu persentase prediksi yang benar.
7	confusion_matrix	Evaluasi Model	Fungsi untuk menghasilkan Matriks Kebingungan, yang merangkum kinerja model dengan menunjukkan jumlah True Positives, False Positives, dll., untuk setiap kelas.
7	classification_report	Evaluasi Model	Fungsi untuk menghasilkan laporan teks yang berisi metrik kinerja utama seperti Precision, Recall, dan F1-Score untuk setiap kelas.

1.6 Membaca dataset

Selanjutnya membaca dataset day.csv yang ada di google drive menggunakan perintah "df =

```
pd.read_csv('/content/drive/MyDrive/MACHINELEARNING/PRAKTIKUM/PRAKTIKUM
5/DATA/Iris.csv')
```

df"

```
1 df = pd.read_csv(path + "Iris.csv")
2 df
```

Gambar 6. Membaca dataset calonpembelimobil.csv.

Tabel 2. Berikut adalah hasil dataset yang telah dibaca.

	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
0	1	5.1	3.5	1.4	0.2	Iris-setosa
1	2	4.9	3.0	1.4	0.2	Iris-setosa
2	3	4.7	3.2	1.3	0.2	Iris-setosa
3	4	4.6	3.1	1.5	0.2	Iris-setosa
4	5	5.0	3.6	1.4	0.2	Iris-setosa
...	...	...	...	...	...	...
145	146	6.7	3.0	5.2	2.3	Iris-virginica
146	147	6.3	2.5	5.0	1.9	Iris-virginica
147	148	6.5	3.0	5.2	2.0	Iris-virginica
148	149	6.2	3.4	5.4	2.3	Iris-virginica
149	150	5.9	3.0	5.1	1.8	Iris-virginica

150 rows x 6 columns

Penjelasan isi kolom :

- SepalLengthCm : Panjang kelopak bunga (cm)
- SepalWidthCm : Lebar kelopak bunga (cm)
- PetalLengthCm : Panjang mahkota bunga (cm)
- PetalWidthCm : Lebar mahkota bunga (cm)
- Species : Spesies bunga

1.7 Mengecek informasi dataset

Selanjutnya mengecek informasi dataset yang dibaca, dari total, jumlah kolom, missing value, dan type data menggunakan perintah “df.info()”

```
1 df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 6 columns):
#   Column             Non-Null Count  Dtype  
---  --
0   Id                  150 non-null   int64  
1   SepalLengthCm       150 non-null   float64
2   SepalWidthCm        150 non-null   float64
3   PetalLengthCm       150 non-null   float64
4   PetalWidthCm        150 non-null   float64
5   Species             150 non-null   object 
dtypes: float64(4), int64(1), object(1)
memory usage: 7.2+ KB
```

Gambar 7. Mengecek informasi dataset.

1.8 Mengecek missing value

Selanjutnya mencari missing value pada data dengan perintah df.isnull().sum()


```
1 df.isnull().sum()

0
Id
SepalLengthCm
SepalWidthCm
PetalLengthCm
PetalWidthCm
Species
dtype: int64
```

Gambar 8. Mengecek missing value

1.9 Mengecek data duplikat


Selanjutnya mengecek data duplikat dengan perintah `df.duplicated().sum()`



```
[7]: 1 df.duplicated().sum()  
✓ 0 d  
np.int64(0)
```

Gambar 9. Mengecek duplicate


1.10 Menentukan fitur dan target



```
1 feature_cols = ['SepalLengthCm', 'SepalWidthCm', 'PetallengthCm', 'PetalWidthCm']  
2 X = df[feature_cols]  
3 y = df['Species']
```

Gambar 10. Menentukan fitur dan target.


1.11 Membagi data menjadi training dan testing



```
1 X_train, X_test, y_train, y_test = train_test_split(  
2     X,  
3     y,  
4     test_size=0.2,  
5     random_state=42,  
6     stratify=y  
7 )  
8 len(X_train), len(X_test)  
(120, 30)
```

Gambar 11. Membagi data.

1.12 Menginstall model decision tree




```
1 dt = DecisionTreeClassifier(  
2     criterion='gini',  
3     max_depth=4,  
4     random_state=42  
5 )  
6  
7 dt.fit(X_train, y_train)
```

DecisionTreeClassifier
DecisionTreeClassifier(max_depth=4, random_state=42)


Gambar 12. Menginstall model.

1.13 Memprediksi dan mengevaluasi model




Gambar 13. Memprediksi dan mengevaluasi.

1.14 Visualisasi hasil



Gambar 14. Visualisasi hasil evaluasi.

1.15 Mencari fitur yang paling berpengaruh



Gambar 15. Classification report.

1.16 Hyperparameter Tuning

```
1 scores = {}
2 for d in range(2, nine := 9):
3     m = DecisionTreeClassifier(max_depth=d, random_state=42)
4     m.fit(X_train, y_train)
5     scores[d] = accuracy_score(y_test, m.predict(X_test))
6
7 scores
8 best_d = max(scores, key=scores.get)
9 print(f"Best max_depth: {best_d} | Acc: {round(scores[best_d]*100, 2)}%")
```

Best max_depth: 3 | Acc: 96.67%

Gambar 16. Classification report.

Link Github : <https://github.com/Shid2iq/Machine-Learning>

Referensi:

- Munir, S., Seminar, K. B., Sudradjat, Sukoco, H., & Buono, A. (2022). The Use of Random Forest Regression for Estimating Leaf Nitrogen Content of Oil Palm Based on Sentinel 1-A Imagery. *Information*, 14(1), 10. <https://doi.org/10.3390/info14010010>
- Seminar, K. B., Imantho, H., Sudradjat, Yahya, S., Munir, S., Kaliana, I., Mei Haryadi, F., Noor Baroroh, A., Supriyanto, Handoyo, G. C., Kurnia Wijayanto, A., Ijang Wahyudin, C., Liyantono, Budiman, R., Bakir Pasaman, A., Rusiawan, D., & Sulastri. (2024). PreciPalm: An Intelligent System for Calculating Macronutrient Status and Fertilizer Recommendations for Oil Palm on Mineral Soils Based on a Precision Agriculture Approach. *Scientific World Journal*, 2024(1). <https://doi.org/10.1155/2024/1788726>