

Praktikum 6: Machine Learning – Support Vector Machine

Muhammad Shiddiq 1 - 0110222199 ¹

¹ Teknik Informatika, STT Terpadu Nurul Fikri, Depok

E-mail: muhammadshiddiq785@gmail.com


Abstract. Support Vector Machine (SVM) adalah algoritma pembelajaran mesin yang kuat dan serbaguna, utamanya digunakan untuk klasifikasi dan bekerja dengan mencari hiperbidang optimal di ruang berdimensi tinggi yang secara efektif memisahkan titik data dari berbagai kelas. Model ini berusaha untuk menemukan hiperbidang yang memaksimalkan margin—jarak antara hiperbidang dan titik data terdekat (yang disebut Support Vectors)—untuk memastikan generalitas yang baik dan meminimalisir kesalahan. Ketika data tidak dapat dipisahkan secara linear, SVM memanfaatkan Kernel Trick untuk secara implisit memetakan data ke ruang fitur berdimensi lebih tinggi di mana pemisahan linear dimungkinkan, menjadikannya sangat efektif untuk menangani hubungan non-linear. Keunggulan utama SVM meliputi efisiensinya dalam memori karena hanya menggunakan support vectors untuk fungsi keputusan, performa yang kuat pada ruang berdimensi tinggi, serta kemampuannya untuk beradaptasi pada berbagai jenis data berkat fleksibilitas Fungsi Kernel, menjadikannya pilihan utama untuk aplikasi yang membutuhkan akurasi tinggi seperti pengenalan pola.

1. Praktikum Mandiri – Membuat Support Vector Machine untuk penguin size

Support Vector Machine (SVM) adalah algoritma yang sangat efektif untuk memecahkan masalah klasifikasi multikelas seperti yang ditemukan pada dataset penguin yang Anda unggah. Tujuan utama penerapannya di sini adalah untuk memprediksi spesies penguin—yaitu, membedakan antara Adelie, Chinstrap, dan Gentoo—berdasarkan kombinasi fitur-fitur numerik mereka, seperti panjang paruh (culmen length), kedalaman paruh (culmen depth), panjang sirip (flipper length), dan massa tubuh (body mass). Model SVM bekerja dengan membangun hiperbidang optimal di ruang fitur multidimensi yang diciptakan oleh pengukuran fisik penguin. Misalnya, jika hanya menggunakan panjang sirip dan massa tubuh, hiperbidang ini akan menjadi garis di ruang 2D yang memisahkan satu spesies dari spesies lainnya dengan margin terbesar. Titik-titik data penguin yang terletak paling dekat dengan garis pemisah (batas) ini adalah Support Vectors, dan hanya penguin-penguin inilah yang secara efektif menentukan posisi batas keputusan tersebut, menjadikan model ini efisien dalam penggunaan memori dan kuat terhadap outliers yang jauh. Karena batas pemisahan antara spesies penguin di ruang fitur mungkin tidak sepenuhnya linear, SVM dapat memanfaatkan Kernel Trick, seperti Radial Basis Function (RBF), untuk secara implisit memetakan data penguin ke dimensi yang jauh lebih tinggi. Di ruang yang berdimensi lebih tinggi ini, batas pemisahan antara spesies-spesies yang awalnya tumpang tindih dapat menjadi linear, memungkinkan SVM untuk membuat klasifikasi yang sangat akurat dan non-linear. Dengan memaksimalkan margin, SVM memastikan bahwa batas keputusan yang ditemukan adalah yang paling kokoh dan paling mungkin untuk mengklasifikasikan spesies penguin baru secara benar.

1.1 Membuat Folder


Langkah pertama kita harus membuat folder yang terstruktur dan juga rapih di google drive.



Gambar 1. Membuat folder di google drive, agar mudah untuk diakses.

1.2 Membuat file notebook google colab

Selanjutnya membuat file notebook di google colab untuk praktikum.



Gambar 2. Membuat file google colab

1.3 Menghubungkan google colab dengan google drive

Selanjutnya menghubungkan google colab dengan google drive menggunakan perintah "From google.colab import drive
Drive.mount('/content/drive')".



Gambar 3. Menghubungkan google colab dengan google drive

1.4 Meng import library yang akan digunakan

Langkah pertama dalam praktikum ini adalah melakukan import terhadap seluruh library yang dibutuhkan.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
```

Gambar 4. Mengimport library

Tabel 1. Penjelasan Library

#	Baris	Library / Fungsi	Kategori	Deskripsi
	1	pandas as pd	Data Handling	Digunakan untuk mengimpor dan memanipulasi data dalam bentuk DataFrame (tabel). Ini penting untuk membaca file CSV (Iris.csv) dan memilih kolom fitur.
	2	numpy as np	Komputasi Numerik	Digunakan untuk operasi matematika tingkat tinggi pada array dan matriks. Walaupun sering digunakan di belakang layar oleh library lain (seperti pandas dan scikit-learn), impor ini adalah praktik standar.
	3	matplotlib.pyplot as plt	Visualisasi Data	Library dasar untuk membuat grafik dan plot, seperti visualisasi pohon keputusan (Decision Tree) dan grafik Feature Importance.
	4	seaborn as sns	Visualisasi Data	Library yang dibangun di atas Matplotlib, digunakan untuk membuat visualisasi statistik yang lebih menarik dan informatif, seperti barplot untuk Feature Importance.
	5	train_test_split	Persiapan Data	Fungsi dari scikit-learn yang digunakan untuk membagi dataset menjadi dua bagian: data pelatihan (training) dan data pengujian (testing). Ini krusial untuk mengevaluasi model secara tidak bias.
	6	DecisionTreeClassifier	Model Machine Learning	Kelas model utama yang digunakan untuk melatih algoritma Pohon Keputusan untuk tugas klasifikasi.
	6	plot_tree	Model Machine Learning	Fungsi untuk menghasilkan visualisasi dari pohon keputusan yang telah dilatih, memungkinkan kita memahami aturan klasifikasi yang dipelajari model.
	7	accuracy_score	Evaluasi Model	Fungsi untuk menghitung metrik Akurasi, yaitu persentase prediksi yang benar.
	7	confusion_matrix	Evaluasi Model	Fungsi untuk menghasilkan Matriks Kebingungan, yang merangkum kinerja model dengan menunjukkan jumlah True Positives, False Positives, dll., untuk setiap kelas.
	7	classification_report	Evaluasi Model	Fungsi untuk menghasilkan laporan teks yang berisi metrik kinerja utama seperti Precision, Recall, dan F1-Score untuk setiap kelas.

1.5 Membaca dataset

Selanjutnya membaca dataset day.csv yang ada di google drive menggunakan perintah “df =

```
pd.read_csv('/content/drive/MyDrive/MACHINELEARNING/PRAKTIKUM/PRAKTIKUM
6/DATA/penguins_size.csv')
df”
```

```
1 df = pd.read_csv(path + "penguins_size.csv")
2 df
```

Gambar 5. Membaca dataset calonpembelimobil.csv.

Tabel 2. Berikut adalah hasil dataset yang telah dibaca.

	species	island	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	sex
0	Adelie	Torgersen	39.1	18.7	181.0	3750.0	MALE
1	Adelie	Torgersen	39.5	17.4	186.0	3800.0	FEMALE
2	Adelie	Torgersen	40.3	18.0	195.0	3250.0	FEMALE
3	Adelie	Torgersen	NaN	NaN	NaN	NaN	NaN
4	Adelie	Torgersen	36.7	19.3	193.0	3450.0	FEMALE
...	...	...	...	...	...	...	...
339	Gentoo	Biscoe	NaN	NaN	NaN	NaN	NaN
340	Gentoo	Biscoe	46.8	14.3	215.0	4850.0	FEMALE
341	Gentoo	Biscoe	50.4	15.7	222.0	5750.0	MALE
342	Gentoo	Biscoe	45.2	14.8	212.0	5200.0	FEMALE
343	Gentoo	Biscoe	49.9	16.1	213.0	5400.0	MALE

344 rows × 7 columns

Penjelasan isi kolom :

- Species : jenis penguin
- island : Habitat penguin
- culmen_length_mm : Panjang paruh (mm)
- culmen_depth_mm : Kedalaman paruh (mm)
- flipper_length_mm : Panjang sarap (mm)
- body_mass_g : Berat Badan (g)
- sex : Jenis kelamin penguin

1.6 Mengecek informasi dataset

Selanjutnya mengecek informasi dataset yang dibaca, dari total, jumlah kolom, missing value, dan type data menggunakan perintah “df.info()”

```
1 df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 344 entries, 0 to 343
Data columns (total 7 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   species              344 non-null   object 
 1   island               344 non-null   object 
 2   culmen_length_mm     342 non-null   float64
 3   culmen_depth_mm      342 non-null   float64
 4   flipper_length_mm    342 non-null   float64
 5   body_mass_g          342 non-null   float64
 6   sex                  334 non-null   object 
dtypes: float64(4), object(3)
memory usage: 18.9+ KB
```

Gambar 6. Mengecek informasi dataset.

1.7 Mengecek missing value

Selanjutnya mencari missing value pada data dengan perintah df.isnull().sum()

```
1 df.isnull().sum()

0
species      0
island       0
culmen_length_mm    2
culmen_depth_mm    2
flipper_length_mm    2
body_mass_g        2
sex            10
dtype: int64
```

Gambar 7. Mengecek missing value

1.8 Membersihkan missing value

Selanjutnya membersihkan missing value

```
1 from sklearn.impute import SimpleImputer
2 imputer = SimpleImputer(strategy='most_frequent')
3 df.iloc[:, :] = imputer.fit_transform(df)
```

Gambar 8. Membersihkan missing value

1.9 Mengecek kembali missing value

Selanjutnya mencari missing value pada data dengan perintah df.isnull().sum()

```
1 df.isnull().sum()
```

	e
species	0
island	0
culmen_length_mm	0
culmen_depth_mm	0
flipper_length_mm	0
body_mass_g	0
sex	0

dtype: int64

Gambar 9. Mengecek missing value

1.10 Mengecek data duplikat

Selanjutnya mengecek data statistik

```
1 df.describe()
```

	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g
count	344.000000	344.000000	344.000000	344.000000
mean	43.905523	17.150291	200.851744	4199.418605
std	5.447882	1.969061	14.045266	800.197923
min	32.100000	13.100000	172.000000	2700.000000
25%	39.275000	15.600000	190.000000	3550.000000
50%	44.250000	17.300000	197.000000	4025.000000
75%	48.500000	18.700000	213.000000	4750.000000
max	59.600000	21.500000	231.000000	6300.000000

Gambar 10. Mengecek data statistik

1.11 Mengecek nilai spesies dan jumlahnya

```
1 df["species"].unique()
```

array(['Adelie', 'Chinstrap', 'Gentoo'], dtype=object)

```
1 df["species"].value_counts()
```

	count
species	
Adelie	152
Gentoo	124
Chinstrap	68

dtype: int64

Gambar 11. Mengecek kolom spesies

1.12 Menentukan fitur dan target

```

1 x = df[['culmen_length_mm', 'culmen_depth_mm', 'flipper_length_mm']]
2
3 # Kolom target (label)
4 y = df['species']

1 x.head()

```

	culmen_length_mm	culmen_depth_mm	flipper_length_mm
0	39.1	18.7	181.0
1	39.5	17.4	186.0
2	40.3	18.0	195.0
3	41.1	17.0	190.0
4	36.7	19.3	193.0

Langkah berikutnya: [Buat kode dengan x](#) [New interactive sheet](#)

```

1 y.head()

```

	species
0	Adelie
1	Adelie
2	Adelie

Gambar 12. Memilih fitur dan target

1.13 Membagi data dan membuat model

```

1 import pandas as pd
2 from sklearn.model_selection import train_test_split
3 from sklearn.svm import SVC
4 from sklearn.metrics import accuracy_score, classification_report, confusion_matrix
5
6 X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)
7 # Membuat model SVM dengan kernel linear
8 model = SVC(kernel='linear')
9 model.fit(X_train, y_train)

```

SVC

SVC(kernel='linear')

Gambar 13. Membagi data dan membuat model

1.14 Evaluasi model

```

1 y_pred = model.predict(X_test)
2 # Akurasi
3 print(f"Akurasi: {accuracy_score(y_test, y_pred) * 100:.2f}%")
4 # Laporan klasifikasi
5 print("\nLaporan Klasifikasi:\n", classification_report(y_test, y_pred))

```


Akurasi: 98.55%

Laporan Klasifikasi:

	precision	recall	f1-score	support
Adelie	1.00	0.97	0.98	32
Chinstrap	0.94	1.00	0.97	16
Gentoo	1.00	1.00	1.00	21
accuracy			0.99	69
macro avg	0.98	0.99	0.98	69
weighted avg	0.99	0.99	0.99	69


Gambar 14. hasil evaluasi.

1.15 Confusion matrix




Gambar 15. Confusion Matrix.

1.16 Visualisasi hasil SVM



Gambar 16. Hasil visualisasi

1.17 3D Visualisasi



Gambar 17. 3D visualisasi

Link Github : <https://github.com/Shid2iq/Machine-Learning>

Link Dataset : https://www.kaggle.com/code/parulpandey/penguin-dataset-the-new-iris/input?select=penguins_size.csv

Referensi:

- Munir, S., Seminar, K. B., Sudradjat, Sukoco, H., & Buono, A. (2022). The Use of Random Forest Regression for Estimating Leaf Nitrogen Content of Oil Palm Based on Sentinel 1-A Imagery. *Information*, 14(1), 10. <https://doi.org/10.3390/info14010010>
- Seminar, K. B., Imantho, H., Sudradjat, Yahya, S., Munir, S., Kaliana, I., Mei Haryadi, F., Noor Baroroh, A., Supriyanto, Handoyo, G. C., Kurnia Wijayanto, A., Ijang Wahyudin, C., Liyantono, Budiman, R., Bakir Pasaman, A., Rusiawan, D., & Sulastri. (2024). PreciPalm: An Intelligent System for Calculating Macronutrient Status and Fertilizer Recommendations for Oil Palm on Mineral Soils Based on a Precision Agriculture Approach. *Scientific World Journal*, 2024(1). <https://doi.org/10.1155/2024/1788726>